

Analiza wpływu kanałów marketingowych na sprzedaż

Wstępna analiza danych (EDA)

Dane obejmowały obserwacje w układzie **tydzień × region** i zawierały koszty kampanii w podziale na kanały, łączną sprzedaż (revenue), liczbę konwersji (conversions), liczbę wyświetleń/ekspozycji (impressions), informacje o promocjach, dane o populacji i market_share.

Taki układ danych sugeruje zastosowanie podejścia panelowego (time × geo), co umożliwia kontrolę różnic regionalnych oraz sezonowości.

Brakujące wartości i ich obsługa

W danych występowały brakujące wartości w kolumnach *impression_tv* oraz *impression_outdoor2*.

Przyjęto podejście biznesowo uzasadnione:

1. Jeśli koszt kampanii w danym tygodniu i regionie był równy 0, brakujące impressions zostały zastąpione wartością 0.
2. W pozostałych przypadkach wypełniono impressions proporcjonalnie do kosztu w danym regionie (z wykorzystaniem relacji impressions/cost obserwowanej w tym regionie). Celem było zachowanie struktury mediowej i spójności z realną mechaniką zakupu mediów.

Analiza zależności zmiennych

W pierwszym kroku wykonano klasyczne wykresy punktowe kosztu danego kanału względem przychodu. Nie zaobserwowano wyraźnej liniowej zależności pomiędzy wydatkami na pojedynczy kanał a przychodem.

Możliwe przyczyny:

1. Efekt opóźniony – reklama może działać przez kilka tygodni.
2. Mieszanie regionów – agregacja wszystkich geo w jednym wykresie maskuje zróżnicowanie regionalne.
3. Wpływ innych kanałów – sprzedaż jest wynikiem kombinacji działań.
4. Sezonowość i promocje – silne czynniki zakłócające.

Wniosek: prosta analiza korelacyjna nie jest wystarczająca do estymacji wpływu marketingu. Konieczne jest podejście modelowe kontrolujące inne czynniki.

Ponadto, zmienna **conversions** była bardzo silnie skorelowana z **revenue**. Oznacza to, że jej uwzględnienie prowadziłoby do problemu endogeniczności. Z tego powodu conversions nie zostały włączone do modelu, aby uniknąć zawyżania dopasowania i błędnej interpretacji wpływu marketingu.

Impressions były silnie zależne od kosztów w kanałach. Oznacza to, że impressions są funkcją wydatków, a ich włączenie do modelu razem z kosztami prowadziłoby do niskich wyników modelu. Ponieważ decyzją budżetową jest koszt, a impressions są jego konsekwencją, do modelu włączono wyłącznie koszty.

Analiza struktury wydatków w podziale na regiony wykazała, że regiony nie różnią się istotnie strukturą rozkładu mediowego, a proporcje wydatków między kanałami są względnie stabilne. Nie było więc potrzeby modelowania odrębnych struktur dla poszczególnych geo.

Modelowanie

Celem modelu była odpowiedź na pytania:

1. Jak zmieni się przychód przy zmianie budżetu o X%?
2. Który kanał jest najbardziej rentowny?

Zastosowano podejście MMM w postaci regresji log-log z transformacją adstock (efekt opóźniony), kontrolą regionów (C(geo)), kontrolą tygodni (C(week)) oraz uwzględnieniem promocji i market_share. Wyniki przedstawione są w tabeli poniżej

Kanał	Elastyczność
Google	0.0115
Outdoor1	0.0112
Facebook	0.0109
TV	-0.0002
TikTok	-0.0021
Outdoor2	-0.0099

Interpretacja:

Przy wzroście budżetu o 10%:

- Google +0.115% przychodu
- Facebook +0.109% przychodu

- Outdoor1 +0.112% przychodu

Kanały TV, TikTok i Outdoor2 wykazują elastyczności bliskie zeru, co sugeruje nasycenie rynku lub możliwą rolę brandingową długoterminową. Warto podkreślić, że ujemne wartości są bardzo małe i interpretowane jako brak wyraźnego efektu, a nie jako realny negatywny wpływ.

Dalsza i bardziej szczegółowa analiza mogłaby obejmować wybór innych modeli, rozważenie dodatkowych zmiennych oraz estymację parametrów adstock zamiast ich założenia.